LAPORAN TUGAS ANALISIS 1
TRANSFORMER & SELF-ATTENTION

Fairuz Istighfar | NIM 60900124044
Sistem Informasi — UIN Alauddin Makassar

1. Dekonstruksi Matematis

Contoh tiga token: “Saya”, “belajar”, “AI”. Q, K berdimensi 3×2 sehingga d■=2; V berdimensi 3×2.

Q = K =

1	0
0	1
1	1

V =

1	0
0	2
2	1

Langkah 1: QK■ = [[1,0,1],[0,1,1],[1,1,2]].
Langkah 2: S = QK■/√d■ = QK■/√2. Scaling mengendalikan skala skor sebelum Softmax.

0.707	0.000	0.707
0.000	0.707	0.707
0.707	0.707	1.414

Langkah 3: A = Softmax(S), dinormalisasi per baris; jumlah tiap baris A = 1.

0.401	0.198	0.401
0.198	0.401	0.401
0.248	0.248	0.503

Langkah 4: O = AV.

1.203	0.797
1.000	1.203
1.255	1.000

Contoh: O■ = 0.401[1,0] + 0.198[0,2] + 0.401[2,1] ≈ [1.203, 0.797]. O adalah gabungan informasi V berbobot perhatian.

2. Encoder dan Decoder: BERT vs GPT

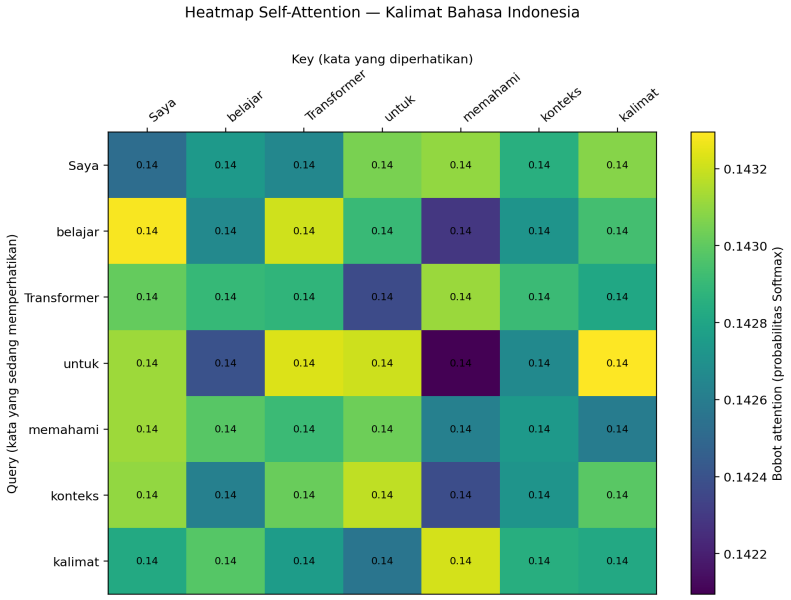
BERT/Encoder: perhatian dua arah memungkinkan token memakai konteks kiri dan kanan. Cocok untuk pemahaman teks, klasifikasi, dan ekstraksi informasi. Keterbatasan: bukan model generatif autoregresif standar untuk menghasilkan teks token demi token.

GPT/Decoder: causal mask menutup token masa depan, cocok untuk memprediksi token berikutnya dan menghasilkan teks. Keterbatasan: saat menghitung perhatian, token tidak dapat melihat konteks masa depan; generasi berlangsung berurutan.

Pada skrip, elemen segitiga atas causal mask bernilai 1 (terlarang). Setelah Softmax, bobot di atas diagonal menjadi 0. Ini menunjukkan perilaku mask, bukan hasil perbandingan langsung model BERT dan GPT terlatih.

3. Eksperimen Kode dan Heatmap

Kalimat uji: “Saya belajar Transformer untuk memahami konteks kalimat.” Sumbu Y = Query (kata yang memperhatikan); sumbu X = Key (kata yang diperhatikan). Nilai lebih besar menunjukkan bobot perhatian lebih besar pada simulasi ini.



Batasan interpretasi: heatmap dibuat dari embedding sintetis dan bobot proyeksi acak dengan seed 42, bukan model bahasa terlatih. Pasangan dengan bobot terbesar hanya hasil numerik dari inisialisasi tersebut; itu bukan bukti pemahaman makna.

Referensi: Vaswani et al. (2017), Attention Is All You Need, https://arxiv.org/abs/1706.03762; Devlin et al. (2019), BERT, https://arxiv.org/abs/1810.04805.